



Tecnológico
de Monterrey

Reporte de Proyecto: Clasificación de actividades de rehabilitación (REHAB)

Alumnos

Diego Angulo - A01643797

Gael Castillo - A01638638

Diego Ibarra - A01644350

Fecha de entrega:

21 de septiembre de 2026

1. Resumen ejecutivo

El Proyecto REHAB compara cinco familias de clasificadores supervisados para reconocer 16 ejercicios de rehabilitación a partir de dos sensores: una pareja de unidades inerciales y un guante de flexión. Las series de tiempo crudas se transforman en una tabla de 480 características estadísticas por repetición y los cinco modelos se entrenan, ajustan y evalúan con el mismo protocolo: división estratificada 50/25/25 con semilla 42, búsqueda en malla en validación con F1-macro como métrica de selección, reentrenamiento con entrenamiento + validación y una única evaluación en prueba.



Dataset: REHAB (16 actividades) | Repeticiones: 4,616 | Características: 480 | División: 2,308 / 1,154 / 1,154 | Semilla: 42 | Configuraciones evaluadas: 118

#	Modelo	Mejor configuración (validación)	Accuracy	Precision	Recall	F1-macro
1	Random Forest	N estimators=100, Max depth=None, Min samples split=2, Class weight=balanced	95.67 %	0.9576	0.9570	0.9556
2	K-Nearest Neighbors	K=1, Pesos=uniform	92.89 %	0.9332	0.9304	0.9291
3	Regresión logística	C=1.0, Class weight=balanced	88.56 %	0.8841	0.8846	0.8831
4	Árbol de decisión	Criterion=entropy, Max depth=10, Min samples split=2, Class weight=balanced	85.79 %	0.8576	0.8577	0.8545
5	Naive Bayes gaussiano	Var smoothing=1e-09, Priors=uniforme, Escalar=False	74.70 %	0.7634	0.7510	0.7406




Figura 1. Accuracy y F1-macro en el conjunto de prueba de los cinco modelos con su mejor configuración.

Random Forest es el modelo seleccionado: 95.67 % de accuracy y 0.9556 de F1-macro en prueba, con 2.78 puntos de accuracy y 0.026 de F1-macro de ventaja sobre K-Nearest Neighbors. 15 de 16 actividades superan $F1 = 0.90$ y la más débil es la actividad 11 ($F1$ 0.87). Además es el modelo más estable ante sus hiperparámetros: sus 36 configuraciones quedan entre 0.940 y 0.963 de F1-macro en validación, frente al árbol individual que oscila entre 0.618 y 0.856.

2. Problema y datos

La variable objetivo actividad toma 16 valores nominales (0 a 15): no existe orden ni distancia entre ellos, por lo que el problema es de **clasificación supervisada multiclase**. En la etapa anterior se probó una regresión lineal cuyas predicciones había que redondear, lo que carece de sentido para categorías; por eso en esta etapa sólo se evaluaron clasificadores. La métrica objetivo es F1-macro porque pondera las 16 actividades por igual.

Cada actividad viene en dos arreglos NumPy de forma (repeticiones, 880, 6): 880 puntos temporales y 6 canales por sensor. Como los clasificadores clásicos esperan una tabla de longitud fija, cada repetición se corta en 4 ventanas de 220 puntos y en cada ventana y canal se calculan 10 estadísticos (media, desviación, mínimo,

cuartiles, máximo, rango intercuartílico, asimetría y curtosis): $4 \times 6 \times 2 \times 10 = 480$ columnas, todas numéricas y sin faltantes. El dataset tabular tiene 4,616 repeticiones, con entre 212 y 385 por actividad (relación 1 : 1.8), un desbalance ligero que motiva probar `class_weight=balanced`. Las escalas son muy heterogéneas, así que los modelos basados en distancia o gradiente se estandarizan dentro de un Pipeline.




Figura 2. Primera repetición de la actividad 0 en ambos sensores; las líneas punteadas marcan las cuatro ventanas de 220 puntos.

3. Metodología de evaluación

Entrenamiento 50 % 2,308 muestras	Validación 25 % 1,154 muestras	Prueba 25 % 1,154 muestras
ajustar cada configuración	elegir hiperparámetros (F1-macro)	evaluación única del modelo final

Modelo final: se reentrena con entrenamiento + validación (3,462 muestras) y se evalúa una sola vez en prueba.

Los cinco scripts comparten el mismo flujo, implementado una sola vez en `scripts/data_utils.py`: (1) división estratificada 50/25/25 con semilla 42; (2) búsqueda en malla entrenando en entrenamiento y midiendo en validación; (3) selección por F1-macro, con accuracy como apoyo y entropía cruzada en los modelos con probabilidades; (4) reentrenamiento con entrenamiento + validación (3,462 muestras); (5) evaluación única en prueba con accuracy, precision, recall, F1 macro, reporte por clase y matriz de confusión; (6) estandarización ajustada sólo con entrenamiento para evitar fuga de información; (7) semilla fija en todos los componentes aleatorios, por lo que los resultados se regeneran exactamente con `make models`.

4. Modelos y búsqueda de hiperparámetros

Modelo	Idea	Malla de hiperparámetros	Co nf.	F1 val. (rango)	Mejor configuración
Random Forest	Ensamble de árboles con bootstrap y submuestreo de ~22 features por nodo; voto mayoritario, <code>n_jobs=-1</code> .	<code>n_estimators</code> : 50, 100, 200; <code>depth</code> : None, 10, 20; <code>min_split</code> : 2, 5; <code>class_weight</code> : None, balanced	36	0.940 - 0.963	<code>N estimators=100</code> , <code>Max depth=None</code> , <code>Min samples split=2</code> , <code>Class weight=balanced</code>
K-Nearest Neighbors	Voto de los K vecinos más cercanos (euclidiana) en el espacio estandarizado de 480 dimensiones.	<code>K</code> : 1, 3, 5, 7, 9; pesos: uniform, distance	10	0.751 - 0.904	<code>K=1</code> , <code>Pesos=uniform</code>
Regresión logística	One-vs-Rest: 16 clasificadores binarios lineales sobre features estandarizadas (lbfgs, <code>max_iter=4000</code>). Línea base interpretable.	<code>C</code> : 0.01, 0.1, 1.0, 10.0; <code>class_weight</code> : None, balanced	8	0.833 - 0.874	<code>C=1.0</code> , <code>Class weight=balanced</code>
Árbol de decisión	Umbral encadenados sobre features sin escalar; captura interacciones pero un solo árbol con 480 features es inestable.	<code>criterion</code> : gini, entropy; <code>depth</code> : None, 5, 10, 20; <code>min_split</code> : 2, 5, 10; <code>class_weight</code> : None, balanced	48	0.618 - 0.856	<code>Criterion=entropy</code> , <code>Max depth=10</code> , <code>Min samples split=2</code> , <code>Class weight=balanced</code>

Modelo	Idea	Malla de hiperparámetros	Co nf.	F1 val. (rango)	Mejor configuración
Naive Bayes gaussiano	Asume normalidad e independencia condicional por clase; frontera cuadrática, casi sin hiperparámetros.	var_smoothing: 1e-09, 1e-06, 1e-03, 1e-01; priors: None, uniforme; escalar: False, True	16	0.607 - 0.755	Var smoothing=1e-09, Priors=uniforme, Escalar=False




Figura 3. Sensibilidad del F1-macro en validación a los hiperparámetros de cada modelo y dispersión de todas las configuraciones probadas.

Lecturas principales: la regresión logística se sobreajusta con $C = 10$ y se subajusta con $C = 0.01$; el árbol necesita profundidad de al menos 10 y a partir de ahí se estabiliza; a Naive Bayes ningún hiperparámetro lo saca de su techo de 76 %, porque los 480 estadísticos están fuertemente correlacionados y violan la independencia; en KNN el F1 decrece monótonamente con K, señal de que cada repetición tiene un vecino casi idéntico; y en Random Forest las 36 configuraciones quedan en un rango de 0.023, con 100 árboles ya saturando la mejora.

5. Resultados

Modelo	F1-macro validación	F1-macro prueba	Diferencia	Peor actividad (F1)
Random Forest	0.9631	0.9556	-0.007	11 (0.87)
K-Nearest Neighbors	0.9043	0.9291	+0.025	1 (0.79)
Regresión logística	0.8736	0.8831	+0.009	9 (0.74)
Árbol de decisión	0.8558	0.8545	-0.001	8 (0.75)
Naive Bayes gaussiano	0.7551	0.7406	-0.014	12 (0.43)

Todos los modelos generalizan de forma estable: la diferencia validación-prueba es pequeña en los cinco casos. Random Forest cambia -0.007, lo esperado al cambiar de partición, y confirma que la malla no se sobreajustó a validación. KNN mejora en prueba (+0.025) porque el modelo final se entrena con 50 % más datos de referencia.




Figura 4. F1 por actividad en prueba para los cinco modelos, ordenados por F1-macro.




Figura 5. Matriz de confusión de Random Forest en prueba (filas: actividad real; columnas: predicción).

Las actividades 8, 9, 11 y 12 son las más difíciles para todos los modelos. En el modelo seleccionado la actividad 11 es la única por debajo de $F1 = 0.90$: recall 1.00 pero precisión 0.77, es decir, absorbe muestras de otras actividades. Confusiones más frecuentes: real 9 predicha 8 (9); real 4 predicha 11 (5); real 12 predicha 11 (4). Las actividades 8 y 9 se confunden en ambos sentidos, lo que sugiere movimientos muy similares.

6. Decisión final y justificación

Modelo seleccionado: Random Forest con N estimators=100, Max depth=None, Min samples split=2, Class weight=balanced.

1. **Es el mejor en todas las métricas de prueba:** 2.8 puntos de accuracy y 0.026 de F1-macro sobre K-Nearest Neighbors, unas 32 repeticiones más bien clasificadas de 1,154; frente a la regresión logística la ventaja es de 7.1 puntos.
2. **La ventaja es consistente:** ganó en validación (0.963 vs 0.904) y en prueba (0.956 vs 0.929), y su desempeño por clase es el más uniforme (15 de 16 clases con F1 > 0.90).
3. **Es el más robusto ante los hiperparámetros** (rango de 0.023 en 36 configuraciones), mientras que en KNN pasar de K = 1 a K = 3 cuesta varios puntos.
4. **Encaja con los datos:** las 480 características son redundantes y el submuestreo de features por nodo hace que el promedio cancele el ruido, lo que explica el salto del árbol individual (85.79 %) al ensamble (95.67 %).

Descartado	Accuracy	Motivo
K-Nearest Neighbors	92.89 %	Muy buen desempeño pero por debajo del ensamble; K = 1 es sensible al ruido y la inferencia compara contra todo el entrenamiento. Se conserva como segunda alternativa.
Regresión logística	88.56 %	La frontera lineal confunde sistemáticamente las actividades 9, 11 y 12. Recomendable sólo si se prioriza interpretabilidad o recursos muy limitados.
Árbol de decisión	85.79 %	Inestable y propenso a sobreajustar con 480 features; el ensamble corrige justo ese problema.
Naive Bayes gaussiano	74.70 %	El supuesto de independencia condicional se viola gravemente y ningún hiperparámetro lo corrige.

Riesgo aceptado. Random Forest es el modelo más pesado: la malla tarda varios minutos y el modelo final guarda 100 árboles completos. El entrenamiento se hace una sola vez y la inferencia sigue siendo de milisegundos por muestra, por lo que la ganancia justifica el costo. **Ética y límites.** REHAB es un dataset público con aprobación ética y sin datos personales; el modelo reconoce qué ejercicio se ejecutó y no diagnostica ni sustituye al fisioterapeuta. Queda pendiente validar con validación cruzada, atender la actividad 11 con nuevas características, recortar features con las importancias del bosque y probar Gradient Boosting.

Reproducibilidad: el código, la división, la semilla y las versiones fijas de las bibliotecas están en el repositorio (commit 23e782c - chore: untrack presentation guide PDF); `make models` regenera todos los números y `make report` este documento. La versión completa con código y salidas se genera con `--completo`.